



从 token 到下一个 token：形状不会凭空消失



展开一个教学用 pre-norm block

跳过 Norm 与 Attention 的残差路径



跳过 Norm 与 FFN 的残差路径

形状示意 | 真实模型可使用 RMSNorm、门控 FFN 与融合算子；此图不表示 kernel 调用次数。