



同时产出更多 token



每个请求也可能等得更久



理论假设 | 14 GB 权重、200 TFLOP/s、1500 GB/s、固定开销 1 ms；未施加容量上限，无排队。