

同一迭代里，prefill 和 decode 可以共同消耗预算

